



有一天，我问自己：指数择时策略构建中的时间序列分析也不是一种假性努力？

就像我们弹钢琴，会出现节奏错误的那一段我们慢慢弹（空仓或卖空），然后剩下乐章又行云流水的弹下去（趋势回归）。

最后，我们又被忽略真相的观众奖励（市场追求趋势，追求过程，而非确定的结果）。

我想了很久，金融市场根本区别于自然科学的研究过程，模式将事实联结与认知，认知复联结于事实。

## 01 波动率时序分析与股票预测

时间序列预测在预测和分析股票价格时，往往被认为是一种‘学术垃圾’，无论是GRACH还是ARCH模型。利用时间序列分析预测下一个时刻的股价/波动率。本质是利用过去信息噪音自回归效应的漂移项，拟合下一刻，尤其预测股票价格，是一种执果索因的行为。所以，在时间序列分析中，预测收益率和波动率常常会是更好的选择，但尽管如此，这实际上是一种低维度的股价预测分析方式。

‘在这篇笔记中，我不考虑股票高频交易的时序分析和择时策略，因为日内频段的数据分析非常复杂，这是另外一种交易方式和思维框架。’

股票的价格形成，已经有非常完备的定价模型和公式，市场是具备一定的有效程度的。无论从发行价的制定到上市后的价格，往往可以基于上市企业的公开财报，行业上下游的结构，以及各项财务指标等构建多因子模型获得更好的股价预测优势。而我接下来的量化笔记会从CAPM模型出发讨论APT套利，并基于Fama-French三因子模型解析多因子模型与因子载荷，因子动物园和构建有效多因子的量化投资框架，包括通过模型截面的差异去预测相对股价的收益。如果有时间可能会写的几篇笔记分别是：1.基于时间序列描述和构建期货的跨期协整配对交易策略 2.机器学习在时间序列和截面分析构建策略的应用。

## 02 择时策略与时序分析

然而，在有效程度和信噪比较低的市场，尤其是加密货币以及期货市场，价格和收益率预测可能会在一段时间内符合随机漫步的形态。基于时间序列分析设计的CTA择时策略，或者马丁格尔策略和变异网格交易策略，都常常会因为设计动能因子加入到量化策略或者利用机器学习LSTM模型并为策略提供择时信号，并在实践中有着相对不错的表现。

而一些优秀的择时策略比如指数增强策略也会把时间序列分析中的趋势指标等择时指标作为应用事件策略/截面分析思路中上百种因子的一部分，从直觉来看，这样做的原因是，因为研究因果关系或相关关系似乎总是会比研究过去信息的漂移项会更加有效。

而学术上讲，我们也可以认为，将时间序列分析中的趋势指标作为因子之一，并与其他截面分析或事件策略因子结合，形成多因子模型，这种方法旨在克服仅仅依赖单一分析方法可能面临的局限性，提高策略的适应性和鲁棒性。

## 03 动量因子的风险调整与GARCH模型

时间序列动量（TSMOM）策略是一种基于价格趋势的投资策略，认为强势价格趋势往往会持续一段时间。TSMOM策略通过计算过去一年的收益率来确定交易信号，正收益率表示多头头寸，负收益率表示空头头寸。买多策略则表示在每个时间步都持有完全的多头头寸。在构建时间序列动量因子时，往往会采用MACD因子通过比较两个不同时间尺度的指数平均来生成买入或卖出信号，以识别趋势的强度和变化。

更高级的方法是采用深度动量网络（Deep Momentum Networks, DMNs），以LSTM作为主要组件，LSTM是一种适用于序列数据的深度学习模型，能够捕捉数据中的长期依赖关系。通过多层神经网络和端到端优化直接优化夏普比率，构建动量策略。

但在构建捕捉持续趋势的投资组合时，我们需要使用波动率调整方法来控制风险。

有期望值才有波动率，有共识才有交易行为。即便是有效程度较低的加密货币或者期货市场，也需要和预测股票价格相似的截面分析，但我们可能更敏感于近期价格波动，而较不关注过去更远期的价格趋势。而GARCH模型在时间序列分析中提供了有力的波动率预测，正是因为GARCH（1，1）lag滞后值为1，缩短了时间窗口长度，我们可以基于GARCH（1，1）/E-GARCH考虑加入有效的动量因子。

## 04 GARCH模型的构建

在上一篇笔记中：

“波动率具有自回归结构的原因是因为金融市场中的波动性是自相关的，即过去的波动性会对未来的波动性产生影响，这是因为金融市场中存在波动性的族群，即在某段时间内出现的高波动性通常会伴随着未来的高波动性。这种波动族群是自相关性的一种表现，因为高波动性期间的波动性通常会延续一段时间。这可能来源于市场中流动性水平的波动性，信息不对称性，非理性的交易群体行为、市场机制等。”

ARCH模型的核心思想是，既然过去的残差（通常是价格或收益率与其均值之间的差异）会影响当前或未来的波动性。这种异方差性是由残差项的平方的时间序列引起的。那我们可以将ARCH模型表示为：

$$\epsilon_t = \sigma_t \cdot z_t$$

其中， $\epsilon_t$  是时间  $t$  的残差， $\sigma_t$  是条件异方差性的函数， $z_t$  是白噪声残差项，它们通常是独立同分布的。

我们对条件异方差性函数  $\sigma_t$  的建模，用过去的残差（通常是价格或收益率与其均值之间的差异）解释当前或预测未来的波动性：

$$\sigma^2(t) = \omega + \alpha_1 \epsilon^2(t-1) + \alpha_2 \epsilon^2(t-2) + \dots + \alpha_p \epsilon^2(t-p)$$

而GARCH模型的可以看作一个平均波动率加上集合所有历史事件引起的条件异方差与平均波动率的差值校正，再加上前一次历史事件冲击的实际波动率与平均方差的差值校正，在ARCH模型上通过考虑集合所有历史事件引起的条件异方差与平均波动率的差值校正强化了条件异方差。

GARCH(1,1)可以用数学公式表示为：

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- 其中：
- $\sigma_t^2$  是时间点 $t$ 的条件方差。
  - $\omega$  是模型的常数项，表示波动性的基本水平。
  - $\alpha$  是模型的参数，表示过去一个时间点的平方残差对当前波动性的影响程度。
  - $\beta$  是模型的参数，表示过去一个时间点的条件方差的平方对当前波动性的影响程度。
  - $\epsilon_{t-1}^2$  是过去一个时间点的平方残差。
  - $\sigma_{t-1}^2$  是过去一个时间点的条件方差的平方。

这个公式表示当前时间点的方差是由三个成分组成的：基础波动性（ $\omega$ ）、上一时间点的平方残差（ $\alpha \epsilon_{t-1}^2$ ），以及上一时间点的条件方差的平方（ $\beta \sigma_{t-1}^2$ ）。

从数学公式中，我们可以清晰地看出来GARCH(1,1)可以被看作是ARCH（ $\infty$ ）的一个截断版本，因为它仅考虑过去一个时间点的平方残差和过去一个时间点的条件方差的平方，相对于无限阶的ARCH，更加简化。

我们还可以对公式进行调整，进一步展开可以得到：

$$\sigma_t^2 = \omega + \beta(\sigma_{t-1}^2 - \omega) + \alpha(\epsilon_{t-1}^2 - \omega)$$

GARCH模型的基本假设之一是，时间序列数据的波动率不是恒定的，而是随着时间的推移而变化。平均波动率表示在没有特殊事件或冲击的情况下，预期的波动率水平。

与ARCH模型一样，GARCH模型考虑了前一次历史事件冲击的实际波动率与平均方差之间的差异校正。这部分校正有助于模型更敏感地捕捉先前波动率冲击的影响，以更好地预测未来的波动率。

但是GARCH模型还考虑了通过引入集合所有历史事件引起的条件异方差与平均波动率之间的差异来校正波动率。这部分考虑了过去的波动率冲击对当前波动率的影响，使得模型能够适应过去事件的影响。

一个典型的GARCH(p, q)模型可以表示为：

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 - j^2$$

总体而言，GARCH模型通过引入条件异方差的概念，考虑过去的波动率冲击，以及实际波动率与平均方差之间的差异，使得模型能够更准确地捕捉和预测金融时间序列中的波动性变化。这对于风险管理和波动率建模在金融领域中非常重要。

## 05 GARCH模型的半衰期

在金融市场中，一个事件的冲击往往会随着时间的推移慢慢消逝，因此，我们可以对波动率族群会随着时间演变速度构建模型。半衰期的计算依赖于  $\alpha + \beta$  的值。

$$h = 1 / \ln(1/2) * [\ln(\alpha + \beta)]$$

这个计算公式表达了在 GARCH(1,1) 模型中，过去波动性对当前波动性的影响在时间上经过一段时间后减半的时间长度。

## 06 GJR-GARCH 模型的杠杆效应 (leverage effect) 和E-GARCH模型

波动率是衡量价格变化幅度或波动性的指标，在时间序列‘执果索因’分析中，可以认为是价格变化的内在因素。波动率通常在市场情绪波动较大或不确定性加大时上升，因为我们会更关注短期内的市场波动，而忽视更长期的投资基本面。

行为经济学研究发现，人们对于损失的敏感度远高于对同等金额收益的敏感度。这种损失厌恶可能导致投资者更为谨慎，更倾向于避免高波动性的资产，而这种针对利空信息的交易行为往往会导致资产价格的波动性加剧（非理性地向交易负向，流动性骤降过去相对空头的交易量的冲击）。

为了衡量因利空消息的情绪对市场的冲击，除了利用自然语言学习NLP通过社交舆情构建恐慌指数，我们还可以直接对历史数据时间序列分析，通过引入 GJR-GARCH 模型，捕捉到市场在利空信息公布后波动性的变化，允许负面的新闻对波动性产生不对称的影响，在针对择时策略的设计中，有效地衡量风险和仓位的调整，适应市场对负面信息的变化。

GJR-GARCH(1,1)模型可以写作：

$$\sigma_t^2 = \omega + (\alpha + \gamma I_t - 1) \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- 其中：
- $\omega$  是基本波动性水平。
  - $\alpha$  是正面（正收益）收益的冲击对波动性的影响。
  - $\gamma$  是负面（负收益）收益的冲击对波动性的非对称影响，
  - $I_t - 1$  是一个指示函数，当  $\epsilon_{t-1} < 0$  时为1，否则为0。
  - $\beta$  是过去波动性的权重。

这个模型包含了 GARCH(1,1) 模型的基本结构，同时引入了 GJR 部分，通过  $\epsilon_{t-1} < 0$  时为1的形式来考虑负向冲击对波动性的不对称影响，其中  $\gamma$  表示杠杆效应的强度。GJR-GARCH 模型中的杠杆效应是指在模型中考虑了条件异方差的情况下，负面的收益冲击对波动性的影响大于正面的收益冲击。这种效应反映了市场在面对损失时对波动性的敏感性相对较高，而在获利时的波动性相对较低的现象。


EGARCH 模型是 GARCH 模型的扩展，引入了对波动性的对数条件。这个模型的特点是能够捕捉到对波动性的非对称影响，类似于 GJR-GARCH 模型，但更为灵活。

EGARCH 模型的条件方差方程可以表示为：

$$\ln(\sigma_t^2) = \omega + \sum_{i=1}^p \alpha_i \left( \left| \frac{\epsilon_{t-i}}{\sigma_{t-i}} \right| - \frac{1}{\sqrt{2\pi}} \right) + \sum_{j=1}^q \beta_j \ln(\sigma_{t-j}^2)$$

EGARCH 模型相对于传统的 GARCH 模型，它在对数条件方差方程中引入了绝对值项 这使得模型能够更好地捕捉到在负向冲击时波动性变化的非对称性。这样，EGARCH 模型可以更灵活地处理金融时间序列中的波动性变化。

总结：时间序列分析为我们研究投资品收益率的行为提供了有力的统计学框架。  
接下来只要我有空，我会从时间序列开始持续地更新自己对量化交易的理解和学习笔记，非常欢迎指正我的错误并一起探讨。



关注我，一起做会独立思考的人，一起成长